

IA generativa e creatività artistica: GAN e CAN a confronto

Materiale di sintesi per il primo colloquio col relatore

Gian — Laurea Magistrale in Ingegneria Informatica (LM-32), Università degli Studi di Bergamo · settembre 2026

Questo documento riassume lo stato del lavoro per orientare la prima conversazione col relatore. Diversi punti — impostazione dell'impianto sperimentale, direzione teorica, peso relativo fra componente tecnica ed etica — sono bozze di lavoro non ancora validate da un relatore e restano esplicitamente aperti alla discussione.

1. Presentazione sintetica del lavoro

Il lavoro si colloca all'intersezione fra intelligenza artificiale generativa, creatività computazionale ed etica dell'IA. Al centro c'è il confronto fra due famiglie di reti generative avversarie (GAN): la GAN nella sua forma originaria, usata come condizione di controllo, e la **Creative Adversarial Network (CAN)** di Elgammal et al. (2017), una variante che modifica esplicitamente il meccanismo di addestramento per produrre immagini stilisticamente ambigue e che, nel presentare questo meccanismo, rivendica di generare arte "creativa".

Il problema. Questa rivendicazione di creatività si basa su una metrica autoreferenziale: la CAN si valuta con il proprio discriminatore, cioè la stessa rete allenata insieme al generatore che poi giudica. Non esiste, nella proposta originale, né una misura indipendente né un criterio filosofico esplicito di cosa costituisca creatività o arte.

L'obiettivo. Verificare quanto questa rivendicazione regge (a) a un confronto empirico con un giudice esterno, mai coinvolto nell'addestramento di nessuno dei due modelli, e (b) a un vaglio teorico esplicito — l'estetica simbolica di Susanne Langer, per cui un'opera d'arte richiede un'"illusione artistica" imbevuta di emozione — per poi discuterne le conseguenze etiche quando la rivendicazione non regge, nella cornice della critica all'**antropomorfizzazione** dei sistemi IA (attribuire loro qualità umane distorce il giudizio su di essi, con conseguenze concrete su come pubblico e artisti percepiscono questi sistemi e il lavoro umano).

Una seconda linea, tenuta volutamente distinta. L'accessibilità che questi strumenti offrono a chi ha lacune tecniche per esprimersi attraverso l'arte visiva è un beneficio reale, e resta **indipendente** dalla legittimità del processo con cui il modello sottostante è stato addestrato (di cui si discutono anche le implicazioni di copyright, dato che i dataset di opere d'arte hanno licenze non banali). Le due valutazioni non si elidono a vicenda: uno strumento può fare del bene a chi lo usa e restare, allo stesso tempo, costruito in un modo eticamente discutibile. La tesi le tiene distinte invece di fondere l'una nell'altra.

Stato attuale. Questa direzione (RQ1 in forma di bozza) è emersa da un lavoro di definizione dell'idea verificato fonte per fonte, ma *non* ancora da una revisione sistematica della letteratura, che resta da fare. È intenzionalmente uno dei punti principali da sottoporre al relatore, insieme al peso relativo che dare alla componente tecnica rispetto a quella etico-analitica nel suo giudizio.

2. Presentazione dell'esperimento

2.1 Impianto sperimentale

Il confronto è controllato a due condizioni — **DCGAN** → **CAN** — con un'unica variabile indipendente: la funzione di perdita. Generatore, backbone del discriminatore, iperparametri, seed e numero di epoche sono identici fra le due condizioni; solo la loss cambia. In questo modo, qualunque differenza osservata nei risultati è attribuibile al meccanismo di ambiguità stilistica e a nient'altro — non a differenze di implementazione. Ogni condizione viene riaddestrata **da zero** (non fine-tuning) e ripetuta su **tre-quattro seed**, perché le GAN oscillano molto fra un'inizializzazione e l'altra e un solo run non distingue un effetto reale dal rumore.

Dataset. ArtBench-10, ristretto a sei stili di **pubblico dominio** e scelti per **massima distanza visiva** reciproca (altrimenti a bassa risoluzione le classi si confondono e non resta nulla da misurare): ukiyo-e, rinascimento, barocco, art nouveau, espressionismo, impressionismo — 30.000 immagini bilanciate. Limite dichiarato: l'espressionismo non è integralmente di pubblico dominio (alcuni autori del primo Novecento sono ancora protetti); è una scelta consapevole per la distanza visiva che offre, da dichiarare esplicitamente in tesi.

2.2 Architetture delle reti (dal codice — `src/tesi_gan/models/networks.py`)

Generatore — identico nelle due condizioni. Segue l'architettura DCGAN di Radford, Metz & Chintala (2016): uno stack di deconvoluzioni (ConvTranspose2d + BatchNorm + ReLU) che mappa un vettore latente $z \sim N(0, I)$ di dimensione 100 in un'immagine RGB (tanh in uscita), con progressione spaziale $4 \times 4 \rightarrow 8 \times 8 \rightarrow 16 \times 16 \rightarrow 32 \times 32 \rightarrow 64 \times 64$ (un livello in più per arrivare a 128×128). Pesi inizializzati a $N(0, 0.02)$, come prescritto dal paper — con l'inizializzazione di default di PyTorch le DCGAN a questa risoluzione collassano molto più spesso.

Discriminatore — backbone condivisa, testa di stile opzionale. Uno stack convoluzionale (Conv2d + BatchNorm + LeakyReLU) identico nelle due condizioni porta l'immagine a una rappresentazione 4×4 ; da lì una testa avversaria (reale/falso) è sempre presente, mentre nella CAN si aggiunge una **seconda testa** — due livelli convoluzionali più due lineari — che classifica lo stile dell'immagine. Un dettaglio tecnico che vale la pena mostrare al relatore: backbone e testa avversaria vengono inizializzate *prima* di costruire la testa di stile, non con un'unica inizializzazione finale — altrimenti, a parità di seed, DCGAN e CAN partirebbero da pesi diversi nella parte condivisa, perché costruire la testa di stile consuma numeri dal generatore pseudocasuale. L'unica differenza architetturale dichiarata fra le due condizioni resta così un solo parametro booleano (`style_head`) — è il punto su cui si regge tutta la validità del confronto.

2.3 Funzioni di perdita

DCGAN (controllo). Gioco minimax non saturante standard (Goodfellow et al., 2014): il discriminatore minimizza $BCE(D(x), 1) + BCE(D(G(z)), 0)$, il generatore minimizza $BCE(D(G(z)), 1)$.

CAN (sperimentale) — due termini aggiuntivi (Elgammal et al., 2017). Al discriminatore si aggiunge una cross-entropy di classificazione dello stile, calcolata **solo sulle immagini reali** (le generate non hanno uno stile "vero" da imparare). Al generatore si aggiunge una **penalità di ambiguità stilistica**, pesata da λ , che spinge la distribuzione di stile predetta sulle immagini generate verso l'uniforme — cioè verso l'essere non attribuibile a nessuno stile riconoscibile.

Punto tecnico ancora aperto, da portare al relatore. Il codice implementa due formulazioni di questa penalità — entropia incrociata rispetto alla distribuzione uniforme, oppure l'opposto dell'entropia — che **non sono equivalenti** (la prima esplode se una classe ha probabilità quasi nulla, la seconda resta limitata). Quale delle due corrisponda davvero alla formulazione del paper originale va verificato e giustificato prima di scriverla in tesi come una scelta univoca.

2.4 Il giudice indipendente dell'ambiguità

Una lacuna trovata rileggendo il codice prima di spendere tempo di calcolo: la testa di stile del discriminatore della CAN non è utilizzabile come metrica di confronto, per due motivi. Non è calcolabile sulla DCGAN (che non ha quella testa), e non è indipendente — quel discriminatore si è allenato *contro* il generatore che poi dovrebbe valutare, chiedendo a una parte in causa di arbitrare la propria partita. La

soluzione adottata è un **classificatore di stile terzo**, della stessa famiglia architeturale del discriminatore, addestrato una sola volta sui soli dati reali e poi **congelato**: lo stesso identico giudice valuta entrambe le condizioni e tutti i seed.

2.5 Risultati sperimentali

Metriche: FID (fedeltà, più basso è meglio), Inception Score (varietà), entropia della posterior di stile del giudice terzo (ambiguità — più alta indica maggiore non-attribuibilità stilistica), copertura degli stili (per escludere che un'alta ambiguità sia in realtà collasso su una zona generica invece che vera fusione stilistica). Tutte accompagnate dalla dichiarazione esplicita di cosa *non* misurano: nessuna delle quattro misura la creatività.

Impianto a 64×64 (dataloader/giudice J2, entropia sui reali 0,531 · soffitto teorico $\log 6 = 1,000$):

Metrica	DCGAN (n=3)	CAN (n=2)*	Atteso	Esito
FID ↓	107,7 ± 6,0	107,3 ± 5,7	CAN peggiore	ipotesi falsificata
Inception Score ↑	4,11 ± 0,27	4,05 ± 0,09	incerto	nessuna differenza
Ambiguità (giudice terzo)	0,682 ± 0,014	0,750 ± 0,013	CAN alta	confermato
Copertura degli stili	0,966 ± 0,003	0,967 ± 0,020	controllo	nessuna differenza

* un terzo run CAN (seed 1) è mode-collapsed (64 campioni quasi identici, copertura 0,190) ed è escluso dalle medie con motivazione esplicita — resta comunque un dato: un run su tre della CAN è collassato, zero su tre della DCGAN.

A questa risoluzione l'ambiguità sale come atteso e i due gruppi non si sovrappongono, **ma il FID non peggiora**: l'ipotesi pre-registrata che la CAN costasse fedeltà è **falsificata**. La copertura identica esclude che l'aumento di ambiguità sia solo collasso su una zona generica.

Impianto a 128×128 (replicato, non sostitutivo, con giudice J3 proprio; entropia sui reali 0,401 — i due impianti non sono confrontabili sulla scala assoluta di ambiguità, solo sull'effetto relativo CAN-DCGAN):

Metrica	DCGAN (n=3)	CAN (n=3)	Atteso	Esito
FID ↓	117,8 ± 8,0	183,4 ± 15,8	CAN peggiore o pari	CAN nettamente peggiore (+55%)
Inception Score ↑	3,72 ± 0,15	3,12 ± 0,14	incerto	DCGAN migliore
Ambiguità (giudice terzo)	0,547 ± 0,021	0,636 ± 0,013	CAN alta	confermato
Copertura degli stili	0,924 ± 0,035	0,809 ± 0,114	controllo	CAN più bassa e dispersa

Qui l'ipotesi **non è più falsificata**: la CAN costa un FID nettamente peggiore. I tre seed CAN toccano il loro minimo di FID tutti alla stessa epoca (20 su 100) e poi degradano quasi monotonicamente — mostrato nel grafico sottostante, che riporta l'intera traiettoria per ogni run (criterio di selezione: FID minimo su tutta la traiettoria, non l'epoca 100 fissa, dopo che un run di controllo era collassato proprio a fine corsa). Se confermata dall'ispezione visiva dei campioni (verifica ancora aperta), l'ipotesi che l'instabilità del meccanismo di ambiguità scali con la risoluzione è il risultato più rilevante di questo impianto.




Figura 1 — Traiettorie complete (11 checkpoint per run) dei sei run a 128px: fedeltà (FID, sinistra) e ambiguità secondo il giudice terzo (destra). Ogni linea è un seed. La linea tratteggiata indica l'entropia misurata sull'arte reale. File: `thesis/figures/generated/traiettorie-128px.png`.

La lettura più solida prodotta finora dal progetto. I due impianti usano giudici e pavimenti di entropia diversi e non sono confrontabili in valore assoluto. Normalizzando però l'incremento CAN-DCGAN sullo spazio utile fra il pavimento (entropia sui reali) e il soffitto teorico $\log(6)$, i due impianti convergono sullo stesso effetto:

Impianto	Arte reale	Spazio utile	DCGAN occupa	CAN occupa	Incremento CAN
64px (giudice J2)	0,531	0,469	32,2 %	46,7 %	+14,5 punti
128px (giudice J3)	0,401	0,599	24,4 %	39,2 %	+14,9 punti

Grezzi, gli incrementi erano +0,068 e +0,089 — sembravano differire di quasi un terzo. Normalizzati sullo spazio in cui l'effetto può manifestarsi, sono praticamente lo stesso numero: due giudici indipendenti, due risoluzioni, run completamente separati, convergono sull'effetto. **Riserva da dichiarare:** a 128px la copertura degli stili è più bassa e dispersa che a 64px, quindi l'esclusione dell'ipotesi "collasso generico" invece di "vera fusione di stile" è più debole a questa risoluzione — serve l'ispezione visiva dei campioni prima di scriverlo come risultato consolidato.

Un'ablazione di controllo con esito inatteso. Con il peso della penalità di ambiguità impostato a zero, la CAN dovrebbe degenerare esattamente nella DCGAN. Il run eseguito (seed 1, 64px) non lo fa: FID 91,7 (sotto tutti e tre i seed DCGAN, 102,3-114,1), Inception Score comparabile, ambiguità 0,652 (sotto il minimo DCGAN, 0,673). Non è un bug né mode collapse. Ipotesi aperta, non ancora verificata: la sola presenza della testa di classificazione di stile nel discriminatore — indipendentemente dal peso della penalità sul generatore — potrebbe già avere un effetto regolarizzante sulla dinamica avversaria. Un solo seed non basta a distinguerlo dalla varianza fra run: serve ripetere l'ablazione su più seed prima di scriverne qualcosa in tesi.

2.6 Esperimento illustrativo (E5) — fuori dal confronto principale

Su richiesta esplicita per ottenere figure più nitide e convincenti da mostrare in tesi, è stato implementato anche un generatore **condizionato per stile**, ispirato al condizionamento categorico di **ArtGAN** (Tan, Chan, Aguirre & Tanaka — riferimento non ancora importato in Zotero, marcato `TODO[CITE]` nel codice: da citare formalmente solo dopo l'importazione) e, in particolare, al progetto studentesco non ufficiale su GitHub github.com/sebastienmeyer2/image-synthesis-artgan, la cui galleria di immagini è apparsa visivamente superiore a quanto prodotto finora dall'impianto DCGAN/CAN, e che lo implementa con modifiche proprie non documentate nel dettaglio.

Perché è tenuto fuori dal confronto principale. ADR-0003 vale perché DCGAN e CAN condividono lo stesso generatore e la stessa backbone del discriminatore, con un'unica variabile indipendente. Un generatore condizionato per stile prende in ingresso anche l'etichetta: è un'architettura diversa per

costruzione, non una terza condizione comparabile. Obiettivo dichiarato: **solo resa visiva**, nessun confronto quantitativo — anche perché la fonte di ispirazione non pubblica FID/IS, solo una galleria curata su compiti diversi (volti, WikiArt per singolo artista, CIFAR-10), non un termine di paragone omogeneo con sei stili art-storici.

Logica tecnica (dal codice — `models/conditional.py`, `training/conditional_losses.py`). L'etichetta di stile in one-hot viene concatenata al vettore latente prima del primo strato del generatore. Il discriminatore ha una testa ausiliaria di classificazione applicata sia alle immagini reali sia a quelle generate — logica AC-GAN — e il generatore è premiato quando l'immagine prodotta è classificata **come lo stile richiesto**: è l'esatto opposto della penalità di ambiguità della CAN, che spinge lontano dalle categorie invece che verso quella richiesta.




Figura 2 — Esperimento illustrativo E5 (64px, seed 1): progressione per epoca, una riga per stile. Onestamente: alcune epoche mostrano ancora artefatti a scacchiera o instabilità di training, non solo gli esiti migliori — nessun numero è associato a questa figura, resta un contrasto visivo. File: `thesis/figures/generated/illustrativo-progressione-64px-seed1.png`.

2.7 Possibili modifiche ed estensioni da discutere

- Verificare sul paper originale di Elgammal et al. (2017) quale delle due formulazioni della penalità di ambiguità è quella corretta, e giustificare la scelta invece di lasciarla implicita.
- Isolare l'effetto della sola presenza della testa di classificazione stilistica nel discriminatore (indipendente dal peso della penalità) con un'ablazione più fine e più seed, per capire se la CAN a peso zero diverge davvero dalla DCGAN.
- Completare l'ispezione visiva sistematica dei campioni a 128px (epoca 20 vs epoca 100) per stabilire se il degrado dei run CAN è collasso di modo o degrado diffuso di qualità.
- Decidere, prima di scrivere le conclusioni, quale esito conta come "informativo" per l'impianto — dato che per costruzione la CAN tende a peggiorare il FID, non è ovvio quale soglia renda il risultato interessante piuttosto che semplicemente negativo.

- Eventuale studio percettivo leggero con soggetti umani (questionario, campione di convenienza) come terza misura accanto a FID e giudice di stile — non ancora eseguito, da ratificare col relatore vista la numerosità bassa e la natura esplorativa, non statisticamente rappresentativa, dei risultati che produrrebbe.
- Importare formalmente in Zotero il paper di ArtGAN prima di citarlo in tesi, e valutare se l'esperimento condizionato meriti un confronto quantitativo dedicato (richiederebbe però una propria baseline e non solo un contrasto visivo).
- Estendere il confronto principale a una terza risoluzione o a un sottoinsieme di stili diverso, se il relatore ritiene che sei stili bastino a sostenere l'argomento o preferisca un impianto più ampio.

2.8 Altre figure: dove si trovano e come recuperarle

Le due figure di questo documento sono le uniche attualmente presenti e integre nel repository locale (`thesis/figures/generated/`). Altre figure previste dal registro degli esperimenti — in particolare le griglie del generatore condizionato a 64px e 128px (campioni per stile, senza la progressione temporale) — sono state generate in una sessione precedente ma **una copia si è persa** per un rinominazione fallita su un pod RunPod (file corrotto, 2 byte) e non è ancora stata rigenerata nel working tree. Per recuperarle prima del colloquio, se servissero: i checkpoint sono al sicuro sul Network Volume persistente RunPod (`/workspace/tesi-gan`); vanno rilanciati i comandi `tesi-gan sample-conditional` e `sample-conditional-progression` puntando a quei checkpoint (sono deterministici dal seed, quindi il risultato è identico a quello già visto). In alternativa, le griglie di campioni per epoca dei run principali (E1-E4, non condizionati) sono già loggate su Weights & Biases (progetto `tesi-gan-creativita`, run id in `experiments/registry.md`) e si possono scaricare direttamente dalla dashboard senza rilanciare nulla. Qualunque figura nuova va comunque prodotta con `python -m tesi_gan.cli export-figures` o gli script dedicati, mai copiata a mano, e salvata in `thesis/figures/generated/` perché resti tracciabile al commit che l'ha generata.

3. Principali spunti dalla letteratura

Rassegna non sistematica (M1, la revisione vera e propria, resta da fare): fonti trovate e verificate una a una nel definire l'idea di tesi. Quelle già importate in Zotero/bibliografia sono citate per nome; le altre sono segnalate come tali.

Fondamenti tecnici (già in bibliografia)

- **Goodfellow et al. (2014)** — formulazione originale delle GAN come gioco minimax fra generatore e discriminatore: è la base su cui poggiano sia la DCGAN sia la CAN.
- **Radford, Metz & Chintala (2016)** — DCGAN: l'architettura convoluzionale di riferimento usata (identica) in entrambe le condizioni dell'impianto.
- **Elgammal, Liu, Elhoseiny & Mazzone (2017)** — CAN: introduce la testa di classificazione di stile e la penalità di ambiguità stilistica, e la rivendicazione di creatività che il lavoro mette alla prova.
- **Heusel et al. (2017)** — Fréchet Inception Distance (FID), la metrica di fedeltà usata, con la sua nota debolezza: si basa su una rete addestrata su fotografie, non su dipinti.
- **Salimans et al. (2016)** — Inception Score, metrica di varietà usata accanto al FID.
- **Saleh & Elgammal (2015)** — classificazione automatica di stile in pittura: base metodologica per il giudice terzo indipendente.
- **Karras et al. (2020, due lavori)** — StyleGAN2 e training con dati limitati: quest'ultimo è il riferimento diretto per il regime "pochi dati" in cui si opera con poche migliaia di immagini per stile.
- **Arjovsky, Chintala & Bottou (2017)** — Wasserstein GAN: alternativa di stabilizzazione del training, tenuta come riferimento per eventuali estensioni.

Creatività computazionale ed estetica (non ancora tutte in bibliografia)

- **Boden (2004)**, *The Creative Mind* — già in bibliografia. Definisce la creatività in opposizione alla pura casualità (combinatoria, esplorativa, trasformativa): un campionamento casuale nello spazio latente non garantisce di per sé valore o novità.
- **Colton (2008)** — già in bibliografia. Distingue esplicitamente creatività percepita da creatività reale in un sistema computazionale: è la cornice diretta della divergenza osservata fra i due giudici di ambiguità (0,28 contro 0,75 a 64px, dato preliminare, non più perno dell'argomento dopo la rilettura più recente).
- **Qi (2019)** — *trovato, da importare*. Applica l'estetica simbolica di Langer direttamente alla CAN e conclude che le manca l'input emotivo, quindi "non è ancora arte" secondo quel criterio: è il paper-ponte fra l'estetica e l'oggetto di studio.
- **Langer (1953/1957)** — *fonte primaria da reperire*, citata finora solo attraverso Qi: se l'argomento entra in tesi, va letta direttamente.
- **Berryman (2024)** — *trovato, dietro paywall*. Critica specificamente la CAN da una prospettiva storico-artistica: basare la creatività sulla sola deviazione stilistica reintroduce un formalismo stile-centrico. Bibliografia interna ricca (Coeckelbergh, McCormack et al., Hertzmann).

Etica dell'IA e locus della creatività (da recuperare)

- **Antropomorfizzazione come fallacia** (letteratura di etica dell'AI, da recuperare) — chiamare un sistema "Creative Adversarial Network" è un atto di antropomorfizzazione che distorce il giudizio morale su di esso: è il nodo che collega la critica estetica alla componente etica richiesta dal corso.
- **Co-creatività uomo-IA** (survey 2024, da recuperare) — modella l'agentività come distribuita lungo un continuum uomo-macchina: base diretta per l'idea che l'emozione stia nell'uso umano dello strumento, non nell'algoritmo.
- **Il dibattito "training = ispirazione umana?"** — sentenze americane che si contraddicono esplicitamente sull'analogia fra addestramento di un modello e lettura/osservazione umana; risolto nel lavoro con il criterio della componente emotiva, sempre assente nel training di un modello generativo, agganciato al "problema del symbol grounding" in filosofia della mente (una semantica solo relazionale, pesi e gradienti, non produce significato vissuto in assenza di un soggetto per cui l'esperienza conti qualcosa).

Elenco completo dei paper individuati e non ancora importati in Zotero: `docs/literature/da-recuperare.md` nel repository.